



Phó Viết Tiến Anh 22022568

Cơ sở dữ liệu (Vietnam National University)



Scan to open on Studeersnel

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



BÁO CÁO HỌC PHẦN DỰ ÁN
Đề tài
NHẬN DIỆN NGÔN NGỮ KÝ HIỆU

Sinh viên:

Phó Viết Tiến Anh - 22022568

Giảng viên hướng dẫn:

Nguyễn Việt Hà

•

•

.....

.....

.....

.....

.....

• • • • •

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Điểm chữ:.....

Hà Nội, ngày 5 tháng 5 năm 2025

Giảng viên đánh giá

(Ký, ghi rõ họ tên)

MỤC LỤC

DANH SÁCH HÌNH ẢNH.....	1
TÓM TẮT.....	2
CHƯƠNG 1: GIỚI THIỆU.....	3
1.1 Bối cảnh và xuất xứ của nghiên cứu.....	3
1.2 Mục tiêu của bài toán nghiên cứu.....	4
1.3 Phương pháp tiếp cận.....	4
1.4 Bố cục các chương còn lại.....	5
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	6
2.1 Ngôn ngữ ký hiệu và bài toán nhận diện.....	6
2.2 Trích xuất keypoints bằng MediaPipe Holistic.....	7
2.3 Kỹ thuật tăng cường dữ liệu cho chuỗi keypoints.....	8
2.3.1 Mục đích của việc tăng cường dữ liệu.....	8
2.3.2 Các kỹ thuật tăng cường dữ liệu được sử dụng.....	9
2.3.3 Kết hợp các kỹ thuật tăng cường.....	11
2.4 Mô hình Mạng Nơ-ron Hồi quy hai chiều LSTM (BiLSTM).....	12

2.4.1 Long Short-Term Memory (LSTM).....	12
2.4.2 Bidirectional LSTM (BiLSTM).....	13
2.4.3 Lý do lựa chọn BiLSTM cho bài toán.....	13
CHƯƠNG 3: PHƯƠNG PHÁP NHẬN DIỆN VSL SỬ DỤNG BiLSTM....	14
3.1 Phương pháp.....	14
3.2 Xây dựng mô hình học sâu.....	15
3.3 Huấn luyện mô hình.....	18
CHƯƠNG 4: THỰC NGHIỆM.....	19
4.1 Môi trường và công cụ thực nghiệm.....	19
4.2 Chuẩn bị dữ liệu.....	20
4.2.1 Thu thập dữ liệu.....	20
4.2.2 Tiền xử lý dữ liệu.....	21
4.3 Kết quả thực nghiệm.....	22
4.4 Triển khai ứng dụng.....	23
4.5 Đánh giá.....	26
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	28
5.1 Kết luận.....	28
5.2 Hướng phát triển.....	29
TÀI LIỆU THAM KHẢO.....	30
PHỤ LỤC.....	31
Mã nguồn.....	31
Phân công công việc.....	31

DANH SÁCH HÌNH ẢNH

Hình 1: Áp dụng MediaPipe Holistic để trích xuất keypoint trên frame.....	8
Hình 2: Trang Từ điển Ngôn ngữ ký hiệu Việt Nam.....	20
Hình 3: Biểu đồ accuracy và loss của mô hình trong quá trình huấn luyện...23	
Hình 4: Giao diện của ứng dụng.....	24
Hình 5: Mô hình dự đoán ký hiệu trong video.....	25
Hình 6: Mô hình dự đoán ký hiệu qua webcam.....	26

TÓM TẮT

Ngôn ngữ ký hiệu Việt Nam (Vietnamese Sign Language – VSL) là phương tiện giao tiếp chính của cộng đồng người khiếm thính. Tuy nhiên, do rào cản ngôn ngữ, phần lớn người bình thường không hiểu VSL, gây cản trở lớn trong quá trình giao tiếp và hòa nhập xã hội của người khiếm thính. Trước thực trạng đó, việc phát triển các hệ thống hỗ trợ nhận diện và phiên dịch ngôn ngữ ký hiệu trở thành một nhu cầu cấp thiết.

Đề tài đề xuất một phương pháp nhận diện ngôn ngữ ký hiệu Việt Nam ở cấp độ từ dựa trên video, ứng dụng các kỹ thuật học sâu. Quá trình thực hiện bao gồm tiền xử lý dữ liệu video, trích xuất đặc trưng không gian – thời gian, kết hợp mô hình học chuỗi LSTM để học và phân loại chuỗi động tác ký hiệu. Hệ thống được huấn luyện và đánh giá trên một tập dữ liệu gồm các câu ký hiệu phổ biến trong VSL.

Kết quả thực nghiệm cho thấy mô hình đạt được độ chính xác cao trong việc nhận diện các ký hiệu với khả năng tổng quát hóa tốt trên dữ liệu kiểm tra. Đề tài góp phần tạo nền tảng cho việc phát triển các hệ thống hỗ trợ giao tiếp cho người khiếm thính trong tương lai.

CHƯƠNG 1: GIỚI THIỆU

1.1 Bối cảnh và xuất xứ của nghiên cứu

Trong xã hội hiện đại, khả năng giao tiếp là yếu tố thiết yếu giúp con người kết nối, học tập, làm việc và sinh hoạt cộng đồng. Tuy nhiên, với những người khiếm thính – không có khả năng nghe và nói – việc giao tiếp thông qua lời nói trở nên gần như không thể. Thay vào đó, họ sử dụng ngôn ngữ ký hiệu để truyền đạt suy nghĩ và cảm xúc.

Ngôn ngữ ký hiệu là một phương tiện giao tiếp quan trọng dành cho người khiếm thính, sử dụng các cử chỉ tay và chuyển động cơ thể để truyền tải thông tin. Ngôn ngữ ký hiệu không chỉ đơn thuần là một hệ thống cử chỉ, mà còn là một hình thức ngôn ngữ đầy đủ, có cấu trúc và ngữ pháp riêng. Tuy nhiên, do chưa được giảng dạy rộng rãi, số người bình thường có khả năng hiểu và sử dụng ngôn ngữ ký hiệu là rất ít, dẫn đến rào cản giao tiếp lớn. Điều này ảnh hưởng không nhỏ đến khả năng hòa nhập, học tập và làm việc của người khiếm thính. Do đó, việc nghiên cứu và phát triển các hệ thống tự động nhận diện ngôn ngữ ký hiệu là vô cùng cần thiết nhằm thu hẹp khoảng cách giao tiếp giữa người khiếm thính và cộng đồng.

Sự phát triển của trí tuệ nhân tạo (AI) và học sâu (deep learning), đặc biệt trong các lĩnh vực xử lý ảnh và video, đã mở ra khả năng xây dựng các hệ thống tự động nhận diện ngôn ngữ ký hiệu, hỗ trợ giao tiếp giữa người khiếm thính và cộng đồng [1]. Từ nhu cầu thực tế đó, đề tài “Nhận diện ngôn ngữ ký hiệu Việt Nam (VSL) sử dụng học sâu” được xây dựng với mục tiêu thiết kế một hệ thống có khả năng phân tích video và tự động nhận diện các ký hiệu do người thực hiện biểu diễn. Mục đích cuối cùng của đề tài là hỗ trợ người

khiểm thính trong giao tiếp, từ đó nâng cao chất lượng cuộc sống và thúc đẩy sự hòa nhập cộng đồng.

1.2 Mục tiêu của bài toán nghiên cứu

Đề tài hướng đến mục tiêu xây dựng một hệ thống có khả năng:

- Tự động nhận diện các ký hiệu trong VSL từ video ngắn.
- Ứng dụng mô hình học sâu để xử lý và phân tích chuỗi động tác phức tạp.
- Đánh giá độ chính xác và tính khả thi của mô hình trên tập dữ liệu thực tế.

Bài toán nghiên cứu đặt ra là: làm thế nào để trích xuất đặc trưng từ video ngôn ngữ ký hiệu và xây dựng một mô hình có thể học và phân loại chính xác nội dung tương ứng.

1.3 Phương pháp tiếp cận

Để giải quyết bài toán, nhóm nghiên cứu sử dụng phương pháp tiếp cận dựa trên trích xuất đặc trưng từ video và học sâu trên chuỗi keypoints. Cụ thể, quá trình được chia thành các bước chính như sau:

- Trích xuất khung hình từ video.
- Phân tích keypoints bằng Mediapipe.
- Tăng cường dữ liệu.
- Chuẩn hóa độ dài chuỗi.
- Lưu dữ liệu huấn luyện.

Dữ liệu đầu ra của quá trình này là tập huấn luyện sẵn sàng để đưa vào mô hình học sâu nhận diện hành động. Nhóm nghiên cứu sử dụng mô hình LSTM để triển khai và đánh giá kết quả trên tập dữ liệu.

Đề tài này sẽ chỉ tập trung vào nhận diện các từ/cụm từ, không đi sâu vào nhận diện các từ liên tục thành câu hoặc các yếu tố biểu cảm khuôn mặt.

1.4 Bố cục các chương còn lại

Chương 2: Cơ sở lý thuyết – Trình bày tổng quan về ngôn ngữ ký hiệu và các hướng tiếp cận chính cho bài toán nhận dạng. Đi sâu vào cơ sở lý thuyết của việc trích xuất keypoint sử dụng MediaPipe. Giải thích các nguyên lý và kỹ thuật tăng cường dữ liệu áp dụng cho dữ liệu chuỗi keypoint. Trình bày kiến thức nền tảng về Long Short-Term Memory (LSTM) và Bidirectional LSTM (BiLSTM) cùng lý do lựa chọn cho bài toán.

Chương 3: Phương pháp nhận diện VSL sử dụng BiLSTM - Mô tả chi tiết phương pháp đề xuất để nhận dạng VSL, bao gồm quy trình xử lý dữ liệu, kiến trúc mô hình BiLSTM cụ thể và quy trình huấn luyện mô hình.

Chương 4: Thực nghiệm - Trình bày chi tiết về bộ dữ liệu sử dụng, quá trình thiết lập thực nghiệm, các kết quả đạt được thông qua các độ đo đánh giá. Phân tích và thảo luận về ý nghĩa của các kết quả này, cũng như những hạn chế gặp phải.

Chương 5: Kết luận và Hướng phát triển - Tóm tắt những đóng góp chính của đề tài, đánh giá lại mục tiêu đã đạt được. Đề xuất các hướng nghiên cứu và phát triển tiềm năng trong tương lai cho hệ thống.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Ngôn ngữ ký hiệu và bài toán nhận diện

Ngôn ngữ ký hiệu hay ngôn ngữ dấu hiệu, thủ ngữ là ngôn ngữ dùng những biểu hiện của bàn tay thay cho âm thanh của tiếng nói. Ngôn ngữ ký hiệu do người khiếm thính tạo ra nhằm giúp họ có thể giao tiếp với nhau trong cộng đồng của mình và tiếp thu tri thức của xã hội. Ngôn ngữ ký hiệu ở Việt Nam đã được hình thành từ rất lâu. Nhưng do trước đây chưa có nhà khoa học nào tìm hiểu, nghiên cứu về nó nên người Việt Nam không nghĩ và đã không xem những dấu hiệu mà người điếc sử dụng là ngôn ngữ. Họ cho rằng đó chỉ là những điệu bộ khuỷa tay của người điếc để cố gắng giao tiếp do thiếu ngôn ngữ. Mãi đến năm 1996, một tiến sĩ ngôn ngữ học người Mỹ là James C. Woodward người đã từng làm việc với William Stokoe tại trường đại học Gallaudet của Mỹ, đã sang Việt Nam thực hiện nghiên cứu về ngôn ngữ ký hiệu của cộng đồng người điếc ở Việt Nam. Theo nghiên cứu của ông, ở Việt Nam hiện có ít nhất 3 ngôn ngữ ký hiệu phổ biến (được cộng đồng người điếc sử dụng nhiều nhất). Ông đã dùng tên của những địa danh này để đặt tên cho 3 ngôn ngữ ký hiệu đó: Ngôn ngữ ký hiệu Hà Nội, ngôn ngữ ký hiệu Hải Phòng, và ngôn ngữ ký hiệu Thành phố Hồ Chí Minh. Sau đó, đã có thêm nhiều dự án được thực hiện để chuẩn hoá ngôn ngữ ký hiệu tại Việt Nam để xây dựng nên hệ thống Ngôn ngữ ký hiệu hoàn chỉnh và thống nhất [2].

Ngôn ngữ ký hiệu Việt Nam(VSL) là phương tiện giao tiếp chủ yếu của cộng đồng người khiếm thính tại Việt Nam. Một câu ký hiệu thường bao gồm chuỗi động tác liên tục được thể hiện bằng tay và thân trên.

Bài toán nghiên cứu của đề tài này là:


Từ một video ngắn thể hiện một câu ký hiệu VSL, làm thế nào để hệ thống có thể tự động phân tích và nhận diện nội dung câu ký hiệu đó?

2.2 Trích xuất keypoints bằng MediaPipe Holistic

Để nhận diện ngôn ngữ ký hiệu, cần trích xuất thông tin hình học mô tả chuyển động cơ thể trong video. Thay vì sử dụng trực tiếp video đầu vào, nhóm nghiên cứu sử dụng thư viện MediaPipe Holistic – một công cụ mã nguồn mở của Google hỗ trợ nhận diện thời gian thực các điểm đặc trưng (keypoints) trên cơ thể người [3]. Việc này giúp mô hình học tập trung vào động tác thay vì yếu tố không quan trọng như màu da, ánh sáng, hoặc nền.

Keypoints là gì? Keypoints là các điểm có ý nghĩa hình học cố định trên cơ thể người (ví dụ: vai, khuỷu tay, cổ tay, đầu gối, mắt, ngón tay...) [4]. Mỗi keypoint thường được biểu diễn bằng tọa độ 2D hoặc 3D (x, y, z) tương ứng với vị trí trong ảnh hoặc trong không gian thực. Trong ngôn ngữ ký hiệu, việc cử động tay, cánh tay và cơ thể trên đóng vai trò chính trong truyền đạt ý nghĩa [5]. Do đó, hệ thống cần theo dõi chính xác vị trí và chuyển động của các keypoints này theo thời gian.

Pose landmark và **Hand landmark** là các loại keypoints, dùng để mô tả các bộ phận khác nhau trên cơ thể người. Pose landmark mô tả các điểm chính của phần thân trên, bao gồm vai, tay, thân trên và hông. Trong khi đó, Hand landmark tập trung vào các điểm trên lòng bàn tay và các ngón tay, điều này đặc biệt quan trọng trong ngôn ngữ ký hiệu, vì nhiều ký hiệu được phân biệt qua các cử động của ngón tay hoặc hướng bàn tay.



Hình 1: Áp dụng MediaPipe Holistic để trích xuất keypoint trên frame

Hình ảnh trên là ví dụ cho việc MediaPipe Holistic trích xuất keypoints trên khung hình. Có thể thấy các điểm keypoints được đánh dấu dựa trên tư thế thân trên và bàn tay. MediaPipe Holistic cung cấp 25 điểm keypoints cho pose thân trên, 21 điểm keypoints cho tay trái và 21 điểm cho tay phải. Tổng cộng, mỗi khung hình được biểu diễn bởi 201 tọa độ (x,y,z) .

Việc sử dụng keypoints có các ưu điểm như: giảm kích thước dữ liệu; loại bỏ nhiễu về màu sắc, ánh sáng; tập trung vào hình học và chuyển động – đặc trưng quan trọng trong ngôn ngữ ký hiệu.

2.3 Kỹ thuật tăng cường dữ liệu cho chuỗi keypoints

2.3.1 Mục đích của việc tăng cường dữ liệu

Hiệu suất của các mô hình học sâu (Deep Learning) phụ thuộc rất lớn vào chất lượng và số lượng dữ liệu huấn luyện. Tuy nhiên, trong bài toán nhận diện ngôn ngữ ký hiệu, việc thu thập một tập dữ liệu lớn, đa dạng và gán nhãn

chính xác là vô cùng tốn kém về thời gian, công sức và chi phí. Dữ liệu ngôn ngữ ký hiệu có tính khan hiếm do:

- Khác biệt trong phong cách ký hiệu của từng cá nhân.
- Tốc độ thực hiện động tác.
- Góc nhìn và bố cục khung hình.
- Các yếu tố nhiễu từ môi trường (nền, ánh sáng...).

Tập huấn luyện quá nhỏ hoặc không đa dạng có thể dẫn đến hiện tượng quá khớp (overfitting), khiến mô hình học thuộc các mẫu cụ thể thay vì học các đặc trưng tổng quát. Điều này làm giảm hiệu quả khi mô hình gặp dữ liệu mới.

Để giải quyết vấn đề này, việc sử dụng kỹ thuật tăng cường dữ liệu (data augmentation) là điều gần như bắt buộc nếu như không muốn mô hình bị overfitting [6]. Đây là quá trình tạo thêm các mẫu huấn luyện mới một cách nhân tạo từ dữ liệu hiện có, thông qua các phép biến đổi hợp lý. Mục tiêu là:

- Tăng kích thước tập dữ liệu huấn luyện mà không cần thu thập thêm dữ liệu thực.
- Tăng tính đa dạng để mô hình ít nhạy cảm hơn với những thay đổi nhỏ không ảnh hưởng đến ý nghĩa thực sự của dữ liệu.
- Giảm overfitting, giúp mô hình học được đặc trưng bất biến, từ đó tổng quát hóa tốt hơn khi gặp tình huống mới.

2.3.2 Các kỹ thuật tăng cường dữ liệu được sử dụng

Dưới đây là các kỹ thuật tăng cường dữ liệu được sử dụng trong đề tài, được áp dụng trực tiếp lên mỗi khung hình.

- **Xoay (Rotation):**

- Cách thực hiện: Áp dụng phép biến đổi xoay (affine transformation) quanh trục z (theo mặt phẳng ảnh), với góc xoay ngẫu nhiên trong khoảng nhỏ (ví dụ ± 10 độ).
- Mục đích: Mô phỏng trường hợp người ký hiệu nghiêng nhẹ hoặc camera không cố định. Thường trong quá trình thu thập dữ liệu, các video chỉ được quay ở một hướng nhất định. Việc xoay tạo ra các phiên bản dữ liệu ở các góc nhìn khác, tăng khả năng khái quát cho mô hình.
- Lợi ích: Giúp mô hình không bị phụ thuộc vào góc quay cố định, xử lý tốt hơn các tình huống góc quay lệch hoặc tư thế nghiêng người.

- **Dịch chuyển (Translation):**

- Cách thực hiện: Dịch toàn bộ các keypoints theo một vector (dx, dy) ngẫu nhiên trong không gian 2D ảnh.
- Mục đích: Mô phỏng các vị trí khác nhau của người ký hiệu trong khung hình (ví dụ: lệch trái, lệch phải, đứng cao hơn hoặc thấp hơn).
- Lợi ích: Giúp mô hình nhận diện được ký hiệu ở bất kỳ vị trí nào trong khung hình, không bị phụ thuộc vào vị trí cố định giữa màn hình.

- **Phóng to/Thu nhỏ (Scaling):**

- Cách thực hiện: Nhân toàn bộ tọa độ keypoints với một hệ số scale ngẫu nhiên (thường từ 0.9 đến 1.1), theo cả trục x và y.
- Mục đích: Mô phỏng người có kích thước cơ thể khác nhau (cao/thấp, mảnh/đậm) hoặc đứng gần/xa máy quay.

- Lợi ích: Giúp mô hình học được các biểu diễn ở nhiều tỷ lệ khác nhau, tăng khả năng chịu biến dạng kích thước.
- **Điều chỉnh tốc độ video (Temporal Speed Variation):**
 - Cách thực hiện: Tăng frame (giảm tốc độ) hoặc giảm frame (tăng tốc độ) rồi nội suy về độ dài chuẩn (60 frame).
 - Mục đích: Mô phỏng các tốc độ ký hiệu khác nhau (nhanh, chậm) giữa các người ký hiệu.
 - Lợi ích: Giúp mô hình không bị lệ thuộc vào tốc độ thực hiện, tăng khả năng nhận diện khi người dùng ký hiệu chậm hoặc nhanh bất thường.
 - **Thay đổi khoảng cách tay (Inter-hand Distance Adjustment):**
 - Cách thực hiện: Giữ nguyên các keypoints của từng bàn tay và của phần thân trên, sau đó áp dụng phép dịch riêng biệt cho từng tay để tăng/giảm khoảng cách hai tay. Tính toán vị trí hợp lý dựa trên giải bài toán inverse kinematics (IK) để đảm bảo cử chỉ không bị biến dạng phi lý.
 - Mục đích: Mô phỏng các phong cách ký hiệu khác nhau: có người ký hiệu với tay mở rộng, có người ký gập cơ thể hơn.
 - Lợi ích: Làm tăng tính đa dạng hình thể mà không làm sai lệch cấu trúc cử chỉ gốc. Đây là một kỹ thuật đặc thù hữu ích với bài toán ký hiệu sử dụng hai tay phối hợp.

2.3.3 Kết hợp các kỹ thuật tăng cường

Trong thực tế, mỗi chuỗi keypoints gốc có thể được tăng cường nhiều lần, mỗi lần áp dụng một hoặc nhiều kỹ thuật trên theo thứ tự ngẫu nhiên. Ví dụ, một chuỗi có thể được rotate + scale + translate trong một lần tăng cường.

Việc kết hợp đa dạng các phép biến đổi này giúp mô hình học được nhiều phiên bản khác nhau của cùng một từ/cụm ký hiệu, tăng khả năng khái quát mà không làm mất đi ý nghĩa ban đầu.

2.4 Mô hình Mạng Nơ-ron Hồi quy hai chiều LSTM (BiLSTM)

Trong bài toán nhận diện từ/cụm từ ký hiệu, dữ liệu đầu vào là các chuỗi keypoints có thứ tự thời gian rõ ràng [7]. Để mô hình hóa tốt các mối quan hệ không gian – thời gian trong chuỗi, nhóm nghiên cứu sử dụng mô hình LSTM và mở rộng thành BiLSTM để khai thác toàn bộ ngữ cảnh của động tác.

2.4.1 Long Short-Term Memory (LSTM)

LSTM là một kiến trúc mạng nơ-ron hồi quy được thiết kế để lưu giữ thông tin trong chuỗi dài và giảm hiện tượng mất gradient [8]. Thay vì chỉ dùng một trạng thái ẩn duy nhất như RNN, LSTM sử dụng thêm một trạng thái bộ nhớ cùng với ba “cổng” điều khiển:

- Cổng quên: chọn thông tin nào cần loại bỏ khỏi bộ nhớ.
- Cổng đầu vào: xác định thông tin mới cần thêm vào bộ nhớ.
- Cổng đầu ra: quyết định thông tin nào được sử dụng làm đầu ra hiện tại.

Cụ thể, tại thời điểm t , các công thức cập nhật trong LSTM như sau:

$$\begin{aligned}
 f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f) && \text{(cổng quên)} \\
 i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i) && \text{(cổng đầu vào)} \\
 \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) && \text{(ứng viên trạng thái bộ nhớ)} \\
 c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t && \text{(cập nhật trạng thái bộ nhớ)} \\
 o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o) && \text{(cổng đầu ra)} \\
 h_t &= o_t \odot \tanh(c_t) && \text{(trạng thái ẩn đầu ra)}
 \end{aligned}$$

trong đó:

- x_t : đầu vào tại thời điểm t .
- h_t : trạng thái ẩn đầu ra tại t .
- c_t : trạng thái bộ nhớ.
- σ : hàm sigmoid.
- $\odot$: phép nhân từng phần tử.

Lợi ích của LSTM trong bài toán nhận diện ký hiệu: lưu giữ được thông tin từ các động tác trước đó, đồng thời giúp mô hình học được các đặc trưng động thời gian dài, như độ trễ đầu tay và dư động cuối tay.

2.4.2 Bidirectional LSTM (BiLSTM)

LSTM chỉ học theo một chiều thời gian (từ quá khứ đến hiện tại). Tuy nhiên, trong bài toán nhận diện từ ký hiệu, toàn bộ chuỗi keypoints đã được biết trước, nên có thể tận dụng thông tin cả trước và sau mỗi thời điểm trong chuỗi.

BiLSTM mở rộng LSTM bằng cách sử dụng hai lớp LSTM [9]:

- Một lớp đi theo chiều thuận $\vec{h}_t$.
- Một lớp đi theo chiều ngược - $\vec{h}_t$.

Đầu ra tại mỗi thời điểm t được kết hợp như sau:

$$h_t = [\vec{h}_t; -\vec{h}_t]$$

Trong đó dấu ; là phép nối vector.

Ưu điểm của BiLSTM:

- Tại mỗi thời điểm, mô hình có cái nhìn toàn diện về ngữ cảnh cả trước và sau.
- Phù hợp với các bài toán nhận diện động tác offline, nơi toàn bộ chuỗi đã có sẵn.

2.4.3 Lý do lựa chọn BiLSTM cho bài toán

Bài toán nhận diện từ/cụm từ từ chuỗi keypoints yêu cầu mô hình:

- Nắm bắt được mối liên hệ giữa các chuyển động kế tiếp.
- Hiểu ngữ cảnh trong toàn bộ chuỗi để phân biệt các từ tương tự nhau.

Vì vậy, nhóm nghiên cứu lựa chọn BiLSTM làm kiến trúc chính thay vì RNN hay LSTM thông thường, nhằm tận dụng triệt để thông tin chuỗi đã biết trước và cải thiện độ chính xác nhận diện.

CHƯƠNG 3: PHƯƠNG PHÁP NHẬN DIỆN VSL SỬ DỤNG BiLSTM

3.1 Phương pháp

Một số nghiên cứu trước sử dụng ảnh RGB hoặc video thô làm đầu vào cho CNN hoặc 3D-CNN [10]. Tuy nhiên phương pháp này có nhiều hạn chế như: đòi hỏi mô hình lớn và tốn dữ liệu; dễ bị ảnh hưởng bởi ánh sáng, nền, trang phục; không tận dụng được thông tin cấu trúc cơ thể.

Từ đó, nhóm nghiên cứu đề xuất cách tiếp cận dựa trên hai thành phần:

- Biểu diễn hình học: trích xuất chuỗi keypoints từ thân trên và tay bằng MediaPipe Holistic.
- Mô hình học chuỗi: sử dụng BiLSTM để học đặc trưng động từ chuỗi keypoints.

Ý tưởng cốt lõi là loại bỏ các thông tin không cần thiết → dùng chuỗi keypoints; mỗi động tác là một chuỗi thời gian → dùng BiLSTM để học mối quan hệ trong chuỗi; đồng thời kết hợp các kỹ thuật tăng cường dữ liệu giúp mô hình học tổng quát tốt hơn.

Để chuyển video thành dữ liệu số cho mô hình học sâu, nhóm nghiên cứu sử dụng MediaPipe Holistic để trích xuất chuỗi keypoints từ mỗi khung hình. Cụ thể, mỗi khung hình sẽ lấy 67 điểm keypoints của thân trên, tay trái và tay phải, mỗi điểm gồm 3 tọa độ (x,y,z) tạo thành vector 201 chiều. Mỗi video sẽ được biểu diễn dưới dạng một chuỗi $X = (x_1, x_2, \dots, x_T)$, với $x_t \in R^{201}$, T là số frame.

Mỗi video có độ dài khác nhau, các chuỗi X , T khác nhau. Tuy nhiên, để huấn luyện mô hình mạng nơ-ron, đầu vào phải có kích thước đồng nhất. Do đó, nhóm nghiên cứu sử dụng phương pháp nội suy (interpolation) để đưa tất cả chuỗi về độ dài chuẩn $T = 60$. Nếu chuỗi ban đầu dài hơn → lấy mẫu lại,

nếu ngắn hơn → nội suy để điền thêm frame trung gian. Kết quả dữ liệu đầu vào có kích thước chuẩn hóa 60×201 .

Vì số lượng video có hạn, nhóm nghiên cứu đã sử dụng các kỹ thuật tăng cường dữ liệu cho keypoints. Các kỹ thuật này giúp mô phỏng sự khác biệt trong phong cách ký hiệu của từng người trong nhiều điều kiện, giúp làm giảm overfitting và tăng khả năng tổng quát của mô hình.

Sau khi đã có đầy đủ dữ liệu, dữ liệu sẽ được đưa vào mô hình học sâu để học và phân loại. Để học được các đặc trưng động theo thời gian trong chuỗi này, đề tài sử dụng mạng BiLSTM nhiều tầng, kết hợp với các lớp chuẩn hóa và dropout để tăng khả năng tổng quát và giảm hiện tượng quá khớp.

3.2 Xây dựng mô hình học sâu

Cấu trúc chi tiết của mô hình học sâu sẽ được trình bày trong bảng dưới đây, mô tả các lớp và thông số của từng thành phần trong mạng.

Layer	Mô tả	Tham số chính
Input	Nhận đầu vào chuỗi keypoint	shape = (60,201)
BiLSTM 1	LSTM 2 chiều, trả về chuỗi	256 units × 2, return_sequence=True, dropout=0.3
BatchNormalization 1	Chuẩn hóa batch	
BiLSTM 2	LSTM 2 chiều, trả về chuỗi	256 units × 2, return_sequence=True, dropout=0.3
BatchNormalization 2	Chuẩn hóa batch	

BiLSTM 3	LSTM 2 chiều, trả về vector	256 units $\times$ 2, <code>return_sequence=False</code> , <code>dropout=0.3</code>
BatchNormalization 3	Chuẩn hóa batch	
Dense 1	Fully connected	512 units, <code>ReLU</code> , <code>Dropout=0.5</code>
BatchNormalization 4	Chuẩn hóa batch	
Dense 2	Fully connected	256 units, <code>ReLU</code> , <code>Dropout=0.5</code>
BatchNormalization 5	Chuẩn hóa batch	
Output	Lớp phân loại	2764 (số nhãn), <code>softmax</code>

Bảng 1: Kiến trúc mô hình

Mô hình học sâu được xây dựng dựa trên mạng BiLSTM (Bidirectional LSTM) với ba khối LSTM chính, kết hợp với các lớp chuẩn hóa, dropout và các lớp Dense. Kiến trúc tổng thể của mô hình được trình bày như sau.

- Lớp Input:
 - Kích thước đầu vào: (60,201), trong đó 60 là số frame của video đã được nội suy về độ dài 60, 201 là số số tọa độ keypoints trong từng frame.
 - Lớp đầu vào này sẽ tiếp nhận dữ liệu và truyền qua các khối LSTM.
- Khối LSTM thứ nhất:
 - Số đơn vị: 256.
 - `return_sequence`: True, đảm bảo rằng đầu ra từ lớp LSTM là một chuỗi, giúp duy trì thông tin cho các lớp tiếp theo.
 - `dropout`: 0.3, giúp giảm hiện tượng quá khớp (overfitting) trong quá trình huấn luyện.

- BatchNormalization: Giúp chuẩn hóa đầu ra của lớp LSTM, giúp mô hình học ổn định hơn.
- Khối LSTM thứ hai
 - Tương tự như khối LSTM đầu tiên, nhưng với đầu vào là kết quả từ lớp LSTM trước đó, giúp mô hình học được các phụ thuộc dài hạn hơn.
 - Số đơn vị LSTM: 256, Dropout: 0.3, BatchNormalization: Thêm vào để cải thiện hiệu quả học.
- Khối LSTM thứ ba:
 - Là khối LSTM cuối cùng với một lớp Bidirectional LSTM có 256 đơn vị. Lớp này không trả về chuỗi (return_sequences = False) vì nó chỉ cần một giá trị cuối cùng để chuyển tới các lớp Dense.
 - dropout: 0.3, BatchNormalization: Tiếp tục được sử dụng để giảm thiểu overfitting và tối ưu quá trình huấn luyện.
- Các lớp Dense:
 - Lớp Dense thứ nhất: 512 đơn vị với hàm kích hoạt ReLU. Đây là lớp fully connected giúp mô hình kết hợp các đặc trưng học được từ các lớp LSTM.
 - Lớp Dense thứ hai: 256 đơn vị với hàm kích hoạt ReLU. Tầng này tiếp tục giúp mô hình học và tinh chỉnh các đặc trưng đã được trích xuất.
- Lớp Output:
 - Lớp đầu ra (Dense): 2764 đơn vị với hàm kích hoạt softmax, được thiết kế để phân loại các đầu ra thành 2764 lớp khác nhau, tương ứng với 2764 từ trong từ điển.

- softmax giúp mô hình tính toán xác suất của từng lớp và chọn lớp có xác suất cao nhất.

3.3 Huấn luyện mô hình

Mô hình được biên dịch với các thiết lập:

- Optimizer: adam.
- Loss function: Sparse Categorical Cross-Entropy.
- Learning rate: 1e-3.
- Metrics: accuracy

Tập dữ liệu được chia thành:

- **80%** dùng huấn luyện.
- **10%** dùng validation (tối ưu mô hình).
- **10%** dùng kiểm thử (đánh giá khách quan).

Các siêu tham số huấn luyện:

- Hàm mất mát (Loss function): `sparse_categorical_crossentropy`.
- Thuật toán tối ưu (Optimizer): Adam.
- Tốc độ học (Learning rate): 1e-3.
- Kích thước lô dữ liệu (Batch size): 32.
- Số epochs: 30.
- Dừng sớm (Early stopping): dừng nếu validation không cải thiện sau 10 epochs.

CHƯƠNG 4: THỰC NGHIỆM

Mục tiêu của chương này là trình bày chi tiết quá trình thực nghiệm nhằm xác minh tính đúng đắn và hiệu quả của phương pháp nhận diện từ/cụm ký hiệu trong ngôn ngữ ký hiệu Việt Nam (VSL) đã đề xuất. Ngoài ra, nhóm nghiên cứu cũng triển khai mô hình thành ứng dụng web đơn giản để đánh giá khả năng áp dụng trong thực tế.

4.1 Môi trường và công cụ thực nghiệm

Đề tài được thực nghiệm trên máy tính cá nhân và Kaggle Notebook.

Máy tính cá nhân:

- Hệ điều hành: Windows 11.
- CPU: Intel Core i5-11300H.
- GPU: tích hợp với CPU - Intel Iris Xe Graphics.
- RAM: 16GB.

Phần huấn luyện mô hình được thực hiện trên Kaggle Notebook với cấu hình:


- Hệ điều hành: Ubuntu.
- GPU: $2 \times$ NVIDIA Tesla T4.
- RAM: 16GB.

Về công cụ phần mềm, ngôn ngữ lập trình được sử dụng là Python. Ưu điểm của nó là dễ sử dụng, câu lệnh ngắn, đơn giản và có nhiều thư viện lớn hỗ trợ. Các thư viện chính được sử dụng là: Selenium, Request – hỗ trợ việc thu thập video từ trang web; Tensorflow – xây dựng mô hình BiLSTM; MediaPipe, Scipy – trích xuất keypoints và nội suy; OpenCV – xử lý ảnh và video; Numpy – xử lý dữ liệu; Scikit-learn – chia tập dữ liệu và đánh giá mô hình; Streamlit – triển khai ứng dụng.

4.2 Chuẩn bị dữ liệu

4.2.1 Thu thập dữ liệu

Dữ liệu ngôn ngữ ký hiệu có sẵn không nhiều và thường không công khai đầy đủ. Do đó, đề tài tiến hành tự thu thập video ký hiệu từ nguồn đáng tin cậy, đó là trang [QIPEDC](http://qipcdc.moet.gov.vn/dictionary) – Từ điển Ngôn ngữ Ký hiệu Việt Nam trực tuyến – thuộc Bộ GD&ĐT. Trang web này cung cấp hàng nghìn video ngắn, mỗi video biểu diễn một từ/cụm từ ký hiệu cụ thể. Các video đều đi kèm thông tin mô tả văn bản, thuận lợi cho việc gán nhãn.



Hình 2: Trang Từ điển Ngôn ngữ ký hiệu Việt Nam

Quy trình crawl video được tự động hóa bằng script Python, sử dụng thư viện Selenium để điều khiển trình duyệt và duyệt từng trang kết quả, tìm kiếm các file .mp4 và nhãn tương ứng. Sau đó sử dụng thư viện Requests để tải các file video về, đồng thời sử dụng ThreadPoolExecutor để tăng tốc độ tải video song song. Mỗi video được đặt tên theo ID cố định và lưu vào thư mục Dataset/Videos. Thông tin nhãn (label) gồm ID, tên file và từ/cụm từ được biểu diễn được lưu trong Dataset/Text/label.csv.

Ví dụ dòng dữ liệu trong label.csv:


```
ID,VIDEO,LABEL
1,D0001.mp4,cảm ơn
2,D0002.mp4,xin lỗi
```

Tổng cộng thu được hơn 4000 video tương ứng với hơn 2700 từ/cụm từ ký hiệu khác nhau.

4.2.2 Tiền xử lý dữ liệu

Mô hình sẽ không huấn luyện trực tiếp từ video thô mà huấn luyện qua chuỗi số biểu thị cho keypoints. Quá trình xử lý dữ liệu bắt đầu từ việc trích xuất keypoints từ video thô, sau đó nội suy chuỗi về độ dài cố định và lưu vào file .npz cùng với nhãn tương ứng. Quy trình này được xây dựng dưới dạng một pipeline tự động hóa, kết hợp MediaPipe và NumPy.

- Sử dụng MediaPipe Holistic để trích xuất keypoints trên toàn bộ frame trên toàn bộ videos.
- Do số frame của mỗi video khác nhau, nên đề tài áp dụng nội suy cubic để đưa toàn bộ chuỗi về độ dài chuẩn là 60.
- Mỗi video biểu diễn văn bản tương ứng được ánh xạ về một số nguyên duy nhất thông qua label_map được lưu trong label_map.json.
- Tạo ra các phiên bản tăng cường từ chuỗi gốc bằng tổ hợp các phép biến đổi. Với mỗi chuỗi gốc, sinh ra tối đa 100 chuỗi tăng cường bằng cách kết hợp các phép biến đổi.
- Dữ liệu được lưu theo cấu trúc:




- Mỗi file .npz chứa hai trường:
 - sequence: chuỗi keypoints đã nội suy, dạng NumPy array.
 - label: số nguyên đại diện cho nhãn.
- Sau khi xử lý toàn bộ dữ liệu, thu được khoảng gần 280.000 tệp .npz tương ứng với hơn 2700 nhãn khác nhau. Dữ liệu sẵn sàng để đưa vào mô hình với định dạng chuẩn 60×201 .

4.3 Kết quả thực nghiệm

Mô hình đạt độ chính xác cao dù số lớp phân loại lớn (2764 lớp), chứng minh hiệu quả của phương pháp đề xuất.

Các chỉ số đánh giá của mô hình trên tập kiểm tra:

- Accuracy: 98.8%.
- Loss: 0.035.
- Precision: 98.9%.
- Recall: 98.7%



Hình 3: Biểu đồ accuracy và loss của mô hình trong quá trình huấn luyện

Biểu đồ cho thấy sự tăng dần của accuracy và giảm dần của loss qua từng epoch trên cả tập huấn luyện và tập validation. Điều này cho thấy mô hình đang học được các đặc trưng của dữ liệu và ngày càng cải thiện độ chính xác.

Việc các đường accuracy và loss của tập huấn luyện và tập validation đều hội tụ chứng tỏ mô hình đang học tốt và đạt được sự cân bằng giữa độ chính xác và mức độ sai số, không có dấu hiệu của overfitting hoặc underfitting.

Đánh giá tổng quát mô hình:

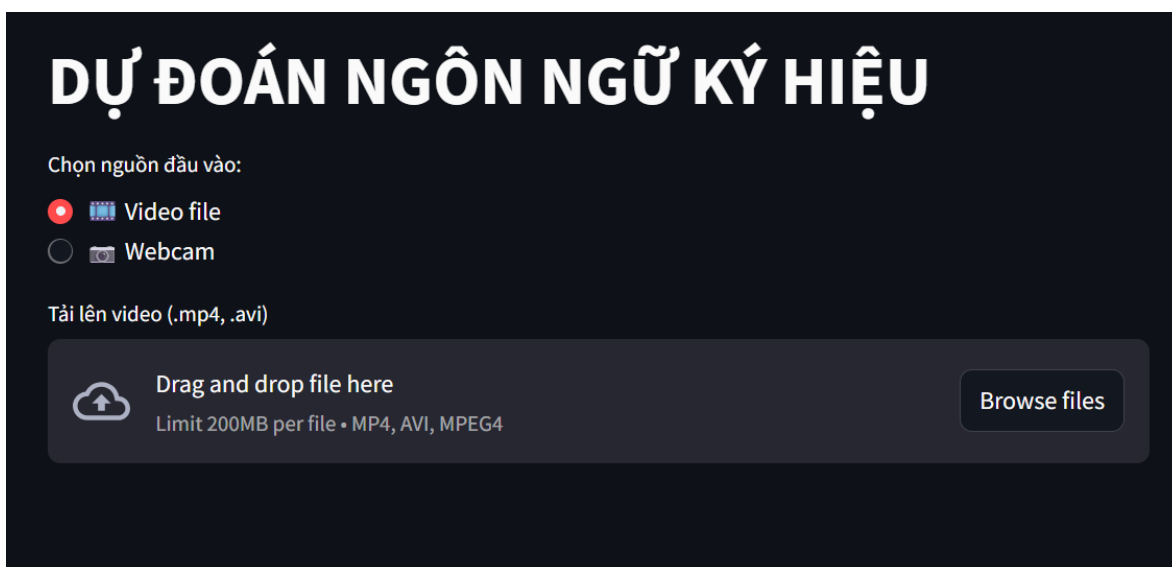
- Mô hình nhẹ, triển khai được trên thiết bị cá nhân.
- Không dùng ảnh RGB → bền vững trước nhiễu.
- Dữ liệu tăng cường giúp giảm overfitting hiệu quả.
- Tuy nhiên vẫn còn hạn chế: mô hình nhận diện độc lập từng từ, chưa xét đến ngữ cảnh liên tục (xử lý câu).

4.4 Triển khai ứng dụng

Mục tiêu: Xây dựng giao diện ứng dụng đơn giản để chứng minh mô hình có thể hoạt động trong thực tế, hỗ trợ người dùng. Công nghệ: Sử dụng


Streamlit tạo giao diện đơn giản, dễ sử dụng. Chức năng chính: Nhận đầu vào từ webcam hoặc video; nhận diện ngôn ngữ ký hiệu qua cử chỉ trong video hoặc webcam.

Ứng dụng được thiết kế với giao diện đơn giản, dễ sử dụng, hỗ trợ cả đầu vào từ video có sẵn và webcam trực tiếp. Hình 4 minh họa giao diện chính của ứng dụng, nơi người dùng có thể lựa chọn nguồn đầu vào, tải lên video, hoặc bật webcam để nhận diện ký hiệu.



Hình 4: Giao diện của ứng dụng

Mô hình có thể dự đoán qua video:



Hình 5: Mô hình dự đoán ký hiệu trong video

Hình 5 thể hiện khả năng nhận diện từ ký hiệu trong video. Sau khi người dùng tải video lên, hệ thống sẽ phân tích và hiển thị kết quả dự đoán tương ứng bên dưới.

Hoặc có thể dự đoán qua webcam:



Hình 6: Mô hình dự đoán ký hiệu qua webcam

Hình 6 minh họa quá trình nhận diện ký hiệu thông qua webcam. Người dùng thực hiện ký hiệu trước webcam, sau đó hệ thống xử lý và hiển thị kết quả dự đoán dựa trên chuỗi keypoint thu được.

4.5 Đánh giá

Quá trình thực nghiệm và triển khai đã khẳng định:

- Phương pháp nhận diện từ/cụm từ qua ký hiệu sử dụng BiLSTM hoạt động hiệu quả.
- Khả năng triển khai ứng dụng thực tế là hoàn toàn khả thi.
- Kết quả đạt được là cơ sở vững chắc cho các hướng phát triển mở rộng như nhận diện câu.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Ngôn ngữ ký hiệu là phương tiện giao tiếp thiết yếu của người khiếm thính, tuy nhiên việc thiếu các công cụ hỗ trợ hiểu và dịch ngôn ngữ ký hiệu khiến quá trình hòa nhập với cộng đồng gặp nhiều rào cản. Xuất phát từ thực tế đó, đề tài này tập trung nghiên cứu và xây dựng hệ thống nhận diện từ/cụm ký hiệu trong ngôn ngữ ký hiệu Việt Nam (VSL) bằng phương pháp học sâu.

Nhóm nghiên cứu đã đề xuất một phương pháp nhận diện sử dụng chuỗi keypoints trích xuất từ video kết hợp với mô hình BiLSTM nhiều tầng. Hệ thống được thiết kế đơn giản nhưng hiệu quả, không phụ thuộc vào ảnh RGB mà chỉ sử dụng thông tin hình học động tác từ MediaPipe Holistic. Toàn bộ dữ liệu được thu thập, gán nhãn, chuẩn hóa và tăng cường theo pipeline tự động hóa. Kết quả thực nghiệm trên hơn 4000 video với 2.764 nhãn khác nhau cho thấy mô hình đạt độ chính xác trên 98%. Đây là kết quả khả quan đối với một hệ thống có số lớp lớn và dữ liệu thu thập thực tế, cho thấy tính đúng đắn và hiệu quả của phương pháp đề xuất. Ngoài ra, nhóm nghiên cứu cũng đã triển khai mô hình dưới dạng ứng dụng web bằng Streamlit, cho phép người dùng thử nghiệm trực tiếp qua webcam hoặc video, chứng minh khả năng áp dụng thực tế của nghiên cứu.

Qua toàn bộ quá trình thực hiện đã rút ra rằng việc sử dụng keypoints làm đặc trưng thay vì ảnh thô giúp mô hình nhẹ hơn, ổn định hơn và phù hợp với bài toán nhận diện động tác như ngôn ngữ ký hiệu. Bên cạnh đó, các kỹ thuật tăng cường dữ liệu chuyên biệt cho chuỗi keypoints đóng vai trò quan trọng trong việc cải thiện khả năng tổng quát của mô hình.

5.2 Hướng phát triển

Mặc dù đã đạt được kết quả khả quan, nghiên cứu vẫn còn một số hạn chế như: mô hình hiện tại mới dừng lại ở nhận diện từ/cụm từ ký hiệu đơn lẻ, chưa xử lý ngữ cảnh liên tục giữa các ký hiệu như trong câu; mới chỉ nhận đầu vào là video cắt sẵn từng từ, chưa thực hiện phân tách từ từ video ký hiệu liên tục. Từ những hạn chế trên, nhóm nghiên cứu đề xuất một số hướng nghiên cứu tiềm năng trong tương lai bao gồm: nhận diện câu ký hiệu hoàn chỉnh bằng cách kết hợp BiLSTM với mô hình ngôn ngữ (Language Model) để học ngữ cảnh liên từ; tăng cường và chuẩn hóa tập dữ liệu VSL, mở rộng phạm vi ký hiệu, kiểm soát cân bằng mẫu và gán nhãn chính xác; Xây dựng ứng dụng hoàn chỉnh nhận diện ngôn ngữ ký hiệu phục vụ cho việc giao tiếp của cộng đồng người khiếm thính.

Kết luận lại, đề tài không chỉ chứng minh được hiệu quả của phương pháp nhận diện VSL bằng BiLSTM và keypoints mà còn mở ra nhiều khả năng phát triển thực tế, đóng góp vào mục tiêu xây dựng các công cụ hỗ trợ người khiếm thính trong tương lai. Đây là bước đi khởi đầu nhưng vững chắc trong hành trình phát triển các hệ thống trợ lý giao tiếp thông minh cho cộng đồng người sử dụng ngôn ngữ ký hiệu tại Việt Nam

TÀI LIỆU THAM KHẢO

- [1] F. Chollet, *Deep Learning with Python*, 2nd ed., Manning Publications, 2021.
- [2] Woodward, J. C. (1996). *Sign Languages and Deaf Identity in Vietnam*. Sign Language Studies.
- [3] Google AI. (2020). *MediaPipe: Cross-platform, customizable ML solutions for live and streaming media*.
- [4] Cao, Z., Simon, T., Wei, S. E., & Sheikh, Y. (2017). *Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields*. In CVPR.
- [5] Fernandez, B., Varona, J., & Pardo, X. M. (2018). *Sign Language Recognition using Pose-Based Features and Recurrent Neural Networks*. In ICPR.
- [6] Shorten, C., & Khoshgoftaar, T. M. (2019). *A survey on image data augmentation for deep learning*. Journal of Big Data, 6(1), 1–48.
- [7] Kim, T., & Cipolla, R. (2009). *Gesture recognition using sequence of learned dynamic poses*. In BMVC.
- [8] Graves, A., & Schmidhuber, J. (2005). *Framewise phoneme classification with bidirectional LSTM networks*. Neural Networks, 18(5–6), 602–610.
- [9] Schuster, M., & Paliwal, K. K. (1997). *Bidirectional recurrent neural networks*. IEEE Transactions on Signal Processing, 45(11), 2673–2681.
- [10] Huang, J., Zhou, W., & Li, H. (2018). *Attention-based 3D-CNNs for large-vocabulary sign language recognition*. IEEE Transactions on Multimedia, 21(9), 2348–2360.

PHỤ LỤC

Mã nguồn

Toàn bộ mã nguồn, tập dữ liệu đã xử lý và mô hình huấn luyện được lưu trữ công khai tại GitHub. Người đọc quan tâm có thể tham khảo, tái hiện hoặc mở rộng nghiên cứu tại địa chỉ:

<https://github.com/photienanh/Vietnamese-Sign-Language-Recognition>

Phân công công việc

Phó Viết Tiến Anh – 22022568: xây dựng mô hình, huấn luyện và triển khai ứng dụng.

Đỗ Quang Dũng – 22022561: thu thập video, xử lý dữ liệu để đưa vào huấn luyện.